

**Problem 1.** Пусть  $\mathbf{X}_0 \sim p^{\text{data}}$  — объект из распределения данных, а  $(\mathbf{X}_t, t = 0, \dots, T)$  — дискретный процесс с сохраняющейся дисперсией

$$\mathbf{X}_t = \sqrt{1 - \beta_t} \mathbf{X}_{t-1} + \sqrt{\beta_t} \varepsilon_t.$$

Предположим, что  $D_t^\theta(\mathbf{x})$  является теоретическим оптимумом в задаче оптимизации

$$\sum_{t=1}^T \mathbb{E} \|D_t^\theta(\mathbf{X}_t) - \mathbf{X}_0\|^2 \rightarrow \min_{\theta},$$

а генерация при помощи  $D_t^\theta(\mathbf{x})$  выглядит следующим образом:

---

**Algorithm 1** Генерация из модели-денойзера

---

$\mathbf{X}_T \sim \mathcal{N}(0, I)$

**for**  $t = T, \dots, 1$  **do**

$\hat{\mathbf{X}}_0 = D_t^\theta(\mathbf{X}_t)$

▷ Предсказываем  $\mathbf{X}_0$  из текущего состояния

$\mathbf{X}_{t-1} \sim p_{t-1|t,0}(\mathbf{X}_{t-1} | \mathbf{X}_t, \hat{\mathbf{X}}_0).$

▷ Шаг назад, используя предсказанный  $\mathbf{X}_0$

**end for**

**return**  $\mathbf{X}_0$

---

Выпишите шаг генерации по Алгоритму 1 в терминах score-функции: покажите, что он будет иметь вид

$$\mathbf{X}_{t-1} = A_t \mathbf{X}_t + B_t \nabla \log p_t(\mathbf{X}_t) + \sqrt{C_t} \varepsilon_t,$$

где  $\varepsilon_t \sim \mathcal{N}(0, I)$ . Найдите  $A_t, B_t, C_t$ .

Покажите, что если взять  $\beta_t = h\gamma_t$ , то  $A_t = 1 + h\frac{\gamma_t}{2} + \bar{o}(h)$  и  $B_t = h\gamma_t + \bar{o}(h)$ .

**Замечание:** если рассмотреть схему генерации из диффузионных моделей с непрерывным временем на основе VP-SDE

$$d\mathbf{Y}_t = -\frac{\gamma_t}{2} \mathbf{Y}_t dt + \sqrt{\gamma_t} d\mathbf{W}_t$$

и соответствующую схему Эйлера для обратного VP-SDE:

$$\mathbf{Y}_{t-h} = \mathbf{Y}_t \left(1 + h\frac{\gamma_t}{2}\right) + h\gamma_t \cdot \nabla \log p_t(\mathbf{Y}_t) + \sqrt{h\gamma_t} \varepsilon_t,$$

то получится очень близкая к Алгоритму 1 схема.

1. Из прошлой дз знаем, что

$$p_{t-1|t,0}(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \mathcal{N} \left( \mathbf{x}_{t-1} \left| \frac{\sqrt{\alpha_{t-1}}\beta_t}{1-\alpha_t} \mathbf{x}_0 + \frac{\sqrt{1-\beta_t}(1-\alpha_{t-1})}{1-\alpha_t} \mathbf{x}_t, \frac{1-\alpha_{t-1}}{1-\alpha_t} \beta_t \right. \right)$$

Теперь можем выписать формулу для  $\mathbf{X}_{t-1}$ :

$$\begin{aligned} \mathbf{X}_{t-1} &= \frac{\sqrt{\alpha_{t-1}}\beta_t}{1-\alpha_t} \hat{\mathbf{X}}_0 + \frac{\sqrt{1-\beta_t}(1-\alpha_{t-1})}{1-\alpha_t} \mathbf{X}_t + \sqrt{\frac{1-\alpha_{t-1}}{1-\alpha_t}} \beta_t \varepsilon_t = \\ &= \frac{\sqrt{\alpha_{t-1}}\beta_t}{1-\alpha_t} D_t^\theta(\mathbf{X}_t) + \frac{\sqrt{1-\beta_t}(1-\alpha_{t-1})}{1-\alpha_t} \mathbf{X}_t + \sqrt{\frac{1-\alpha_{t-1}}{1-\alpha_t}} \beta_t \varepsilon_t \quad (1) \end{aligned}$$

Так как денойзер  $D_t^\theta$  обучен на VP процесс, то скор функция может быть записана следующим образом:

$$\nabla \log p_t(\mathbf{x}) = \frac{\sqrt{\alpha_t} D_t^\theta(\mathbf{x}) - \mathbf{x}}{1 - \alpha_t}$$

Почему именно так (обсуждалось на семинаре, но всё же): процесс VP, знаем как выглядит распределение в момент времени  $t$  при фиксированном  $\mathbf{X}_0$ ; тогда как будто записали плотность этого распределения, взяли логарифм и производную, получили мат.ожидание минус точку и поделить на дисперсию.

Попробуем подогнать выражение 1, чтобы увидеть там скор функцию:

$$\begin{aligned}
\mathbf{X}_{t-1} &= \frac{\sqrt{\alpha_{t-1}}\beta_t}{1-\alpha_t} D_t^\theta(\mathbf{X}_t) + \frac{\sqrt{1-\beta_t}(1-\alpha_{t-1})}{1-\alpha_t} \mathbf{X}_t + \sqrt{\frac{1-\alpha_{t-1}}{1-\alpha_t}} \beta_t \varepsilon_t = \\
&= \frac{\sqrt{\alpha_t} D_t^\theta(\mathbf{X}_t) - \mathbf{X}_t \sqrt{\alpha_{t-1}}\beta_t}{1-\alpha_t} - \frac{\mathbf{X}_t \sqrt{\alpha_{t-1}}\beta_t}{1-\alpha_t} + \frac{\mathbf{X}_t \sqrt{\alpha_{t-1}}\beta_t}{1-\alpha_t} + \frac{\sqrt{1-\beta_t}(1-\alpha_{t-1})}{1-\alpha_t} \mathbf{X}_t + \sqrt{\frac{1-\alpha_{t-1}}{1-\alpha_t}} \beta_t \varepsilon_t = \\
&= \nabla \log p_t(\mathbf{X}_t) \frac{\sqrt{\alpha_{t-1}}\beta_t}{\sqrt{\alpha_t}} + \mathbf{X}_t \frac{\sqrt{\alpha_{t-1}}\beta_t + \sqrt{\alpha_t}\sqrt{1-\beta_t}(1-\alpha_{t-1})}{(1-\alpha_t)\sqrt{\alpha_t}} + \sqrt{\frac{1-\alpha_{t-1}}{1-\alpha_t}} \beta_t \varepsilon_t = \\
&= \nabla \log p_t(\mathbf{X}_t) \frac{\beta_t}{\sqrt{1-\beta_t}} + \mathbf{X}_t \frac{\sqrt{\alpha_{t-1}}\beta_t + \sqrt{\alpha_t}\sqrt{1-\beta_t}(1-\alpha_{t-1})}{(1-\alpha_t)\sqrt{\alpha_t}} + \sqrt{\frac{1-\alpha_{t-1}}{1-\alpha_t}} \beta_t \varepsilon_t \quad (2)
\end{aligned}$$

Отдельно ещё рассмотрим коэфф перед  $\mathbf{X}_t$ :

$$\begin{aligned}
\frac{\sqrt{\alpha_{t-1}}\beta_t + \sqrt{\alpha_t}\sqrt{1-\beta_t}(1-\alpha_{t-1})}{(1-\alpha_t)\sqrt{\alpha_t}} &= \sqrt{\alpha_{t-1}} \frac{\beta_t + \sqrt{1-\beta_t}\sqrt{1-\beta_t}(1-\alpha_{t-1})}{(1-\alpha_t)\sqrt{\alpha_t}} = \\
&= \frac{1}{\sqrt{1-\beta_t}} \frac{\beta_t + (1-\beta_t)(1-\alpha_{t-1})}{(1-\alpha_t)} = \frac{1}{\sqrt{1-\beta_t}} \frac{\beta_t + 1 - \beta_t - \alpha_t}{(1-\alpha_t)} = \frac{1}{\sqrt{1-\beta_t}} \quad (3)
\end{aligned}$$

Итого получили, что

$$\begin{aligned}
A_t &= \frac{1}{\sqrt{1-\beta_t}} \\
B_t &= \frac{\beta_t}{\sqrt{1-\beta_t}} \\
C_t &= \frac{1-\alpha_{t-1}}{1-\alpha_t} \beta_t
\end{aligned} \quad (4)$$

2. Теперь подставим  $\beta_t = h\gamma_t$ :

(a) в  $A_t$ :

$$\frac{1}{\sqrt{1-\beta_t}} = \frac{1}{\sqrt{1-h\gamma_t}} = (1-h\gamma_t)^{-1/2} = 1 + \frac{h\gamma_t}{2} + \bar{o}(h)$$

(b) в  $B_t$ :

$$\frac{\beta_t}{\sqrt{1-\beta_t}} = \frac{h\gamma_t}{\sqrt{1-h\gamma_t}} = h\gamma_t \left( 1 + \frac{h\gamma_t}{2} + \bar{o}(h) \right) = h\gamma_t + \bar{o}(h)$$

**Problem 2.** Пусть случайная величина  $\mathbf{X}$  имеет распределение с плотностью  $p(\mathbf{x})$ . Покажите, что функционал обучения score функции

$$\frac{1}{2} \mathbb{E} \|s_\theta(\mathbf{X}) - \nabla \log p(\mathbf{X})\|^2 \rightarrow \min_\theta$$

1. в одномерном случае с точностью до константы, не зависящей от  $\theta$ , совпадает с функционалом

$$\mathbb{E} \left( \frac{1}{2} (s_\theta(\mathbf{X}))^2 + \frac{\partial}{\partial \mathbf{x}} s_\theta(\mathbf{X}) \right) \rightarrow \min_\theta;$$

в предположении, что

$$\lim_{\mathbf{x} \rightarrow +\infty} s_\theta(\mathbf{x})p(\mathbf{x}) = \lim_{\mathbf{x} \rightarrow -\infty} s_\theta(\mathbf{x})p(\mathbf{x}) = 0;$$

2. в общем случае с точностью до константы, не зависящей от  $\theta$ , совпадает с функционалом

$$\mathbb{E} \left( \frac{1}{2} \|s_\theta(\mathbf{X})\|^2 + \operatorname{div} s_\theta(\mathbf{X}) \right) \rightarrow \min_\theta$$

в предположении, что

$$\lim_{\|\mathbf{x}\| \rightarrow +\infty} s_\theta(\mathbf{x})p(\mathbf{x}) = 0;$$

3. выведите из этого, что score-функцию можно обучать с помощью минимизации

$$\mathbb{E} \left( \frac{1}{2} \|s_\theta(\mathbf{X})\|^2 + \left\langle \frac{\partial}{\partial \mathbf{x}} s_\theta(\mathbf{X}) \varepsilon, \varepsilon \right\rangle \right) \rightarrow \min_\theta,$$

где  $\varepsilon$  — независимая с  $\mathbf{X}$  величина с  $\mathbb{E} \varepsilon = 0$ ,  $\operatorname{Var} \varepsilon = I$ .

**Замечание:** предположение про предел имеет смысл, так как идеальное решение  $s_\theta(\mathbf{x}) = \nabla \log p(\mathbf{x})$  удовлетворяет  $\nabla \log p(\mathbf{x}) \cdot p(\mathbf{x}) = \nabla p(\mathbf{x})$ , что логично предположить нулем на бесконечности, так как там плотность нулевая и не меняется.

1. Перепишем, как выглядит выражение в одномерном случае:

$$\frac{1}{2} \mathbb{E} \left[ \left( s_\theta(\mathbf{X}) - \frac{\partial}{\partial \mathbf{x}} \log p(\mathbf{X}) \right)^2 \right] =$$

Теперь раскроем квадрат:

$$= \frac{1}{2} \mathbb{E} \left[ (s_\theta(\mathbf{X}))^2 + \left( \frac{\partial}{\partial \mathbf{x}} \log p(\mathbf{X}) \right)^2 - 2s_\theta(\mathbf{X}) \frac{\partial}{\partial \mathbf{x}} \log p(\mathbf{X}) \right]$$

Слагаемое посередине является константой по  $\theta$ :

$$= \frac{1}{2} \mathbb{E} \left[ (s_\theta(\mathbf{X}))^2 - 2s_\theta(\mathbf{X}) \frac{\partial}{\partial \mathbf{x}} \log p(\mathbf{X}) \right] = \mathbb{E} \left[ \frac{1}{2} (s_\theta(\mathbf{X}))^2 \right] - \mathbb{E} \left[ s_\theta(\mathbf{X}) \frac{\partial}{\partial \mathbf{x}} \log p(\mathbf{X}) \right]$$

Посмотрим отдельно на второе мат.ожидание:

$$\begin{aligned} \mathbb{E} \left[ s_\theta(\mathbf{X}) \frac{\partial}{\partial \mathbf{x}} \log p(\mathbf{X}) \right] &= \int_{-\infty}^{+\infty} s_\theta(\mathbf{x}) \frac{\partial}{\partial \mathbf{x}} \log p(\mathbf{x}) p(\mathbf{x}) d\mathbf{x} = \left\{ \frac{\partial}{\partial \mathbf{x}} \log p(\mathbf{x}) = \frac{\frac{\partial}{\partial \mathbf{x}} p(\mathbf{x})}{p(\mathbf{x})} \right\} = \\ &= \int_{-\infty}^{+\infty} s_\theta(\mathbf{x}) \frac{\partial}{\partial \mathbf{x}} p(\mathbf{x}) d\mathbf{x} = \int_{-\infty}^{+\infty} \frac{\partial}{\partial \mathbf{x}} s_\theta(\mathbf{x}) p(\mathbf{x}) d\mathbf{x} - \int_{-\infty}^{+\infty} p(\mathbf{x}) \frac{\partial}{\partial \mathbf{x}} s_\theta(\mathbf{x}) d\mathbf{x} = \\ &= \left\{ \text{по предположению} \int_{-\infty}^{+\infty} \frac{\partial}{\partial \mathbf{x}} s_\theta(\mathbf{x}) p(\mathbf{x}) d\mathbf{x} = s_\theta(\mathbf{x}) p(\mathbf{x}) d\mathbf{x} \Big|_{-\infty}^{+\infty} = 0 \right\} = \\ &= - \int_{-\infty}^{+\infty} p(\mathbf{x}) \frac{\partial}{\partial \mathbf{x}} s_\theta(\mathbf{x}) d\mathbf{x} = -\mathbb{E} \left[ \frac{\partial}{\partial \mathbf{x}} s_\theta(\mathbf{X}) \right] \end{aligned}$$

Возвращаясь назад, получаем:

$$\mathbb{E} \left[ \frac{1}{2} (s_\theta(\mathbf{X}))^2 \right] + \mathbb{E} \left[ \frac{\partial}{\partial \mathbf{x}} s_\theta(\mathbf{X}) \right] = \mathbb{E} \left[ \frac{1}{2} (s_\theta(\mathbf{X}))^2 + \frac{\partial}{\partial \mathbf{x}} s_\theta(\mathbf{X}) \right]$$

2. Опять же, раскрываем скобки с сразу выкинем член, не влияющий на оптимизацию:

$$\mathbb{E} \left[ \frac{1}{2} \|s_\theta(\mathbf{X})\|^2 - \langle s_\theta(\mathbf{X}), \nabla \log p(\mathbf{X}) \rangle \right] =$$

Посмотрим на второй член отдельно:

$$\begin{aligned} \mathbb{E} [\langle s_\theta(\mathbf{X}), \nabla \log p(\mathbf{X}) \rangle] &= \int_{-\infty}^{+\infty} p(\mathbf{x}) \langle s_\theta(\mathbf{x}), \nabla \log p(\mathbf{x}) \rangle d\mathbf{x} = \int_{-\infty}^{+\infty} \langle s_\theta(\mathbf{x}), \nabla p(\mathbf{x}) \rangle d\mathbf{x} = \\ &= \int_{-\infty}^{+\infty} \sum_{i=1}^n s_\theta^{(i)}(\mathbf{x}) \frac{\partial}{\partial x_i} p(\mathbf{x}) d\mathbf{x} = \left\{ s_\theta^{(i)}(\mathbf{x}) \frac{\partial}{\partial x_i} p(\mathbf{x}) = \frac{\partial}{\partial x_i} (s_\theta^{(i)}(\mathbf{x}) p(\mathbf{x})) - p(\mathbf{x}) \frac{\partial}{\partial x_i} s_\theta^{(i)}(\mathbf{x}) \right\} = \\ &= \int_{-\infty}^{+\infty} \sum_{i=1}^n \frac{\partial}{\partial x_i} (s_\theta^{(i)}(\mathbf{x}) p(\mathbf{x})) d\mathbf{x} - \int_{-\infty}^{+\infty} \sum_{i=1}^n p(\mathbf{x}) \frac{\partial}{\partial x_i} s_\theta^{(i)}(\mathbf{x}) d\mathbf{x} = 0 - \int_{-\infty}^{+\infty} p(\mathbf{x}) \operatorname{div} s_\theta(\mathbf{x}) d\mathbf{x} = -\mathbb{E} [\operatorname{div} s_\theta(\mathbf{X})] \end{aligned}$$

Почем интеграл занулился: меняем сумму с интегралом, далее интеграл по  $d\mathbf{x}$  можем записать как  $dx_1 dx_2 \dots dx_n$  и, по теореме Фубини, можем менять интегралы местами, один занулился по предположению, а за ним и остальные.

Тогда получаем:

$$= \mathbb{E} \left[ \frac{1}{2} \|s_\theta(\mathbf{X})\|^2 + \operatorname{div} s_\theta(\mathbf{X}) \right]$$

3. Введём обозначение  $\operatorname{div} s_\theta(\mathbf{X}) = \operatorname{Tr}(J)$ , где  $J$  – якобиан  $s_\theta(\mathbf{X})$ . Тогда поработаем отдельно со вторым слагаемым:

$$\begin{aligned} \mathbb{E} [\operatorname{div} s_\theta(\mathbf{X})] &= \mathbb{E} [\operatorname{Tr}(J)] = \operatorname{Tr}(\mathbb{E}[J]) = \operatorname{Tr}(\mathbb{E}[J]\mathbf{I}) = \operatorname{Tr}(\mathbb{E}[J]\mathbb{E}[\varepsilon\varepsilon^\top]) = \operatorname{Tr}(\mathbb{E}[J\varepsilon\varepsilon^\top]) = \operatorname{Tr}(\mathbb{E}[\varepsilon^\top J\varepsilon]) = \\ &= \mathbb{E}[\operatorname{Tr}(\varepsilon^\top J\varepsilon)] = \mathbb{E}[\varepsilon^\top J\varepsilon] = \mathbb{E}[\langle J\varepsilon, \varepsilon \rangle] \end{aligned}$$

### Problem 3.

1. Пусть  $\mathbf{X}, \mathbf{Z}$  – независимые величины. Покажите, что

$$\nabla \log p_{\mathbf{X}+\mathbf{Z}}(\mathbf{y}) = \mathbb{E} [\nabla \log p_{\mathbf{X}}(\mathbf{X}) | \mathbf{X} + \mathbf{Z} = \mathbf{y}].$$

2. Предложите на основе первого пункта функционал обучения score функции

$\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$  шумного распределения, если известна score функция чистого распределения

$\nabla_{\mathbf{x}} \log p_0(\mathbf{x})$ , а прямой процесс задан VE-SDE

$$\begin{cases} d\mathbf{X}_t = g(t)d\mathbf{W}_t; \\ \mathbf{X}_0 \sim p_0. \end{cases}$$

1.

$$\begin{aligned} \nabla \log p_{\mathbf{X}+\mathbf{Z}}(\mathbf{y}) &= \frac{\nabla p_{\mathbf{X}+\mathbf{Z}}(\mathbf{y})}{p_{\mathbf{X}+\mathbf{Z}}(\mathbf{y})} = \frac{1}{p_{\mathbf{X}+\mathbf{Z}}(\mathbf{y})} \nabla_{\mathbf{y}} \int_{-\infty}^{+\infty} p_{\mathbf{X}}(\mathbf{y}-t) p_{\mathbf{Z}}(t) dt = \frac{1}{p_{\mathbf{X}+\mathbf{Z}}(\mathbf{y})} \nabla_{\mathbf{y}} p_{\mathbf{X}}(\mathbf{y}-t) p_{\mathbf{Z}}(t) dt = \\ &= \{s = \mathbf{y} - t, \nabla_{s+t} p_{\mathbf{X}}(s) = \nabla_s p_{\mathbf{X}}(s), dt = |-1|dv\} = \frac{1}{p_{\mathbf{X}+\mathbf{Z}}(\mathbf{y})} \int_{-\infty}^{+\infty} \nabla_s p_{\mathbf{X}}(s) p_{\mathbf{Z}}(\mathbf{y} - s) ds = \\ &= \{p_{\mathbf{Z}}(\mathbf{y} - s) = p_{\mathbf{X}+\mathbf{Z}|\mathbf{X}}(\mathbf{y}|s)\} = \frac{1}{p_{\mathbf{X}+\mathbf{Z}}(\mathbf{y})} \int_{-\infty}^{+\infty} \nabla_s p_{\mathbf{X}}(s) p_{\mathbf{X}+\mathbf{Z}|\mathbf{X}}(\mathbf{y}|s) ds = \\ &= \frac{1}{p_{\mathbf{X}+\mathbf{Z}}(\mathbf{y})} \int_{-\infty}^{+\infty} \nabla_s \log p_{\mathbf{X}}(s) p_{\mathbf{X}}(s) p_{\mathbf{X}+\mathbf{Z}|\mathbf{X}}(\mathbf{y}|s) ds = \int_{-\infty}^{+\infty} \nabla_s \log p_{\mathbf{X}}(s) p_{\mathbf{X}|\mathbf{X}+\mathbf{Z}}(s|\mathbf{y}) ds = \\ &= \mathbb{E} [\nabla \log p_{\mathbf{X}}(\mathbf{X}) | \mathbf{X} + \mathbf{Z} = \mathbf{y}] \end{aligned}$$

2. У нас был следующий функционал (для фиксированного  $t$ ):

$$\mathbb{E} \|s_t^\theta(\mathbf{X}_t) - \nabla \log p_t(\mathbf{X}_t)\|^2 \rightarrow \min_\theta$$

Подробнее рассмотрим  $p_t$ :

$$p_t(\mathbf{x}) = p_{\mathbf{X}_t}(\mathbf{x})$$

Так как процесс VE, то  $\mathbf{X}_t = \mathbf{X}_0 + \varepsilon_t \sqrt{\int_0^t g(s)^2 ds}$ , тогда

$$p_{\mathbf{X}_t}(\mathbf{x}) = p_{\mathbf{X}_0 + \varepsilon_t \sqrt{\int_0^t g(s)^2 ds}}(\mathbf{x})$$

Так как оба слагаемых в плотности независимые, то можем воспользоваться результатом первого пункта:

$$\nabla \log p_t(\mathbf{x}) = \nabla \log p_{\mathbf{X}_0 + \varepsilon_t \sqrt{\int_0^t g(s)^2 ds}}(\mathbf{x}) = \mathbb{E} \left[ \nabla \log p_{\mathbf{X}_0}(\mathbf{X}_0) \middle| \mathbf{X}_0 + \varepsilon_t \sqrt{\int_0^t g(s)^2 ds} = \mathbf{x} \right]$$

По условию,  $\nabla \log p_{\mathbf{X}_0}(\mathbf{X}_0) = \nabla \log p_0(\mathbf{X}_0)$  известен. Соответственно, пользуясь свойством, что минимизация квадрата разности функции и условного мат.ожидания с точностью до константы – это минимизация квадрата разности этой функции и то, почему мы мат.ожидали, получаем:

$$\mathbb{E} \left\| s_t^\theta \left( \mathbf{X}_0 + \varepsilon_t \sqrt{\int_0^t g(s)^2 ds} \right) - \nabla \log p_0(\mathbf{X}_0) \right\|^2 \rightarrow \min_\theta$$